

Extração de equações interpretáveis de redes neurais em grafo para identificação de um sistema MIMO de abastecimento de água

Rodrigo Watanabe Pisaia¹

rodrigo.watanabe0107@gmail.com

Professor orientador: Prof. Dr. Aron Luiz Oliveira dos Santos

Centro Universitário Curitiba (Unicuritiba) – Engenharia

Resumo

Modelos caixa-preta de identificação de sistemas, como redes neurais, costumam superar modelos lineares clássicos em acurácia, mas não produzem uma equação que possa ser inspecionada ou usada em projeto de controle. Este trabalho propõe e avalia um método de extração de equações interpretáveis a partir de uma rede neural em grafo (*Graph Neural Network*, GNN) treinada para identificar um sistema MIMO de abastecimento de água do reservatório São José (Sanepar), com quatro entradas (frequência de três bombas e vazão de entrada) e três saídas (vazão de distribuição, nível e pressão). O método baseia-se em uma *Message Passing Neural Network* cuja função de mensagem recebe apenas variáveis físicas nomeadas (janelas de defasagem de cada série), em vez de um vetor latente sem nome, e é regularizada por penalidade L1 para que a mensagem aprendida vire uma transformação linear da interação verdadeira entre as variáveis. Regressão simbólica é então aplicada separadamente sobre a função de mensagem e sobre a função de atualização do modelo treinado, produzindo expressões fechadas candidatas a lei física. Em paralelo, a norma da mensagem por aresta fornece uma matriz de topologia de acoplamento, validada contra causalidade de Granger e identificação ARX clássica. Resultados preliminares de acurácia mostram que as arquiteturas em grafo superam o ARMAX de referência (120 parâmetros) em previsão de 12 passos nas três saídas, com a variante regularizada (*message_dim=8*) obtendo o melhor desempenho em vazão e pressão entre as redes testadas. A extração simbólica da equação permanece em andamento; o artigo documenta o método, a implementação (disponível como pacote Python) e os resultados de acurácia já obtidos como base para a etapa de destilação.

Palavras-chave: Identificação de sistemas. Redes neurais em grafo. Regressão simbólica. Sistemas MIMO. Interpretabilidade.

1 Introdução

Sistemas de abastecimento de água municipal, como estações de bombeamento e reservatórios, são sistemas dinâmicos de múltiplas entradas e múltiplas saídas (MIMO) cuja operação eficiente depende de modelos matemáticos confiáveis. Ferrari e Coelho (2025) identificaram um sistema desse tipo – o reservatório São José, operado pela Sanepar em Curitiba – usando um modelo ARMAX de ordem 3 com aproximadamente 120 parâmetros, ajustado por metaheurísticas multiobjetivo (NSGA-II, MOGWO, MOCS). O modelo obtido é preciso (R^2 entre 0,84 e 0,96

na validação), mas é, nas palavras dos próprios autores, uma estrutura polinomial genérica sem relação direta com a física do processo – não há equação que relacione as saídas ao balanço de massa do reservatório ou à curva das bombas.

Esse é precisamente o tipo de lacuna que métodos recentes de destilação simbólica de redes neurais se propõem a fechar. Cranmer et al. (2020) mostraram que, ao treinar uma rede neural com uma estrutura interna separável – uma *Graph Network* (BATTAGLIA et al., 2018) – e regularizar o componente de mensagem entre nós, é possível depois substituir esse componente por uma expressão simbólica obtida via regressão simbólica, recuperando leis físicas conhecidas (leis de força, por exemplo) a partir apenas dos dados, e até descobrindo uma fórmula nova para a concentração de matéria escura em simulações cosmológicas. O ganho central do método é fatorar o problema: em vez de buscar simbolicamente sobre a rede inteira, busca-se sobre funções internas pequenas, cada uma com poucas entradas.

Este trabalho aplica essa ideia ao sistema do reservatório São José. A pergunta de pesquisa não é apenas *prever* as três saídas do sistema, mas *extrair uma equação interpretável* que explique o acoplamento entre as variáveis – e, secundariamente, a topologia desse acoplamento (quais entradas afetam quais saídas). A hipótese de trabalho é que um modelo de identificação em grafo, mais simples que uma GNN "profunda" e pensado desde o início para a extração, consegue (i) igualar ou superar a acurácia do ARMAX de referência com uma ordem de grandeza menos parâmetros e (ii) produzir uma expressão simbólica que recupere, pelo menos qualitativamente, o balanço de massa conhecido do reservatório ($A \, dy_2/dt = u_4 - y_1$).

O restante do artigo está organizado da seguinte forma: a Seção 2 revisa os fundamentos de redes de mensagens, destilação simbólica e explicação de GNNs; a Seção 3 descreve os dados, a arquitetura proposta e o método de extração; a Seção 4 apresenta os resultados de acurácia obtidos até o momento e discute o estado da extração simbólica; a Seção 5 conclui.

2 Referencial teórico

2.1 Identificação de sistemas MIMO e o caso do reservatório São José

Identificação de sistemas é o processo de construir um modelo matemático de um sistema dinâmico a partir de dados de entrada e saída observados (LJUNG, 1999). Para sistemas multivariáveis, ferramentas clássicas como o *Relative Gain Array* (RGA) (BRISTOL, 1966; SKOGESTAD; POSTLETHWAITE, 2005) e a causalidade de Granger (GRANGER, 1969) permitem quantificar o acoplamento entre pares entrada-saída sem assumir uma estrutura de modelo específica, e servem de referência independente para validar a topologia que um modelo mais complexo aprender.

O sistema-alvo deste trabalho é o reservatório São José (Sanepar, Curitiba/PR), com quatro entradas – frequência das bombas 1, 2 e 3 (Hz) e vazão de entrada (l/s) – e três saídas – vazão de distribuição (l/s), nível do reservatório (m) e pressão (mca), amostradas a cada hora. Ferrari

e Coelho (2025) ajustaram a esse sistema um modelo ARMAX MIMO de ordem 3, com 120 parâmetros estimados por seis metaheurísticas distintas, usando 1.100 das 2.216 amostras disponíveis. O nível do reservatório foi a saída mais difícil de ajustar: estratégias mono-objetivo produziram R^2 negativo (até $-15,9$), o que os autores atribuem à diferença de ordem de grandeza entre as saídas na agregação do erro. A física conhecida do sistema é simples – um balanço de massa de primeira ordem no nível, $A dy_2/dt = u_4 - y_1$, e relações quase algébricas de perda de carga para vazão e pressão – mas essa estrutura não é explícita em um modelo ARMAX de ordem genérica, o que motiva buscar um método capaz de recuperá-la a partir dos dados.

2.2 Redes de mensagens e o viés indutivo de grafo

Uma *Message Passing Neural Network* (MPNN) (GILMER et al., 2017) representa um sistema como um grafo cujos nós trocam mensagens ao longo das arestas. Em uma rodada de propagação, para cada par de nós (i, j) :

$$m_{ij} = \psi(h_i, h_j) \quad (1)$$

em que h_i é a representação (*feature*) do nó i e ψ é uma função aprendida, tipicamente uma rede neural pequena, compartilhada entre todas as arestas. As mensagens recebidas por um nó são agregadas, geralmente por soma, e combinadas com a própria representação do nó por uma segunda função aprendida ϕ :

$$\hat{y}_i = \phi\left(h_i, \sum_{j \neq i} m_{ij}\right) \quad (2)$$

Este trabalho usa o sistema de sete variáveis (quatro entradas, três saídas) como os sete nós de um grafo completo e fixo – a topologia não é aprendida, só o conteúdo das mensagens –, com a janela de defasagem de cada série como a representação h_i do respectivo nó. É essa escolha de representação, com argumentos nomeáveis em vez de um vetor latente genérico, que torna ψ e ϕ candidatas à destilação simbólica da próxima subseção.

2.3 Destilação simbólica

Regressão simbólica busca, no espaço de expressões matemáticas, a fórmula que melhor ajusta um conjunto de dados, sem fixar a priori a forma dessa expressão – tipicamente via programação genética (KOZA, 1992). Schmidt e Lipson (2009) mostraram ser possível redescobrir leis de conservação a partir de dados de sistemas físicos puramente por busca simbólica, mas o método escala mal com o número de variáveis de entrada, pois o espaço de expressões cresce combinatorialmente.

Cranmer et al. (2020) resolvem esse problema de escala combinando regressão simbólica com uma MPNN: em vez de buscar sobre o modelo inteiro, busca-se separadamente sobre ψ e ϕ (Equações 1 e 2), cada uma com poucas entradas. O passo crítico é regularizar a dimensão da

mensagem m_{ij} durante o treino – os autores usam penalidade L1 com peso 10^{-2} – o que força ψ a se tornar uma transformação aproximadamente linear da interação física verdadeira, em vez de uma codificação arbitrária de alta dimensão. Sem essa regularização, o R^2 entre a mensagem aprendida e a força física verdadeira, no experimento de referência dos autores, foi de 0,000; com L1, 1,000. A regularização é o mesmo princípio do LASSO (TIBSHIRANI, 1996), que empurra coeficientes irrelevantes exatamente a zero.

A ferramenta empregada para a busca simbólica propriamente dita é o PySR (CRANMER, 2023), cujo motor é uma implementação em Julia de um algoritmo evolutivo de múltiplas populações: cada expressão candidata é representada como uma árvore de operadores, mutada e simplificada ao longo de gerações, com as constantes de cada candidata otimizadas numericamente. A saída não é uma única expressão, mas uma frente de Pareto de complexidade contra erro, da qual se escolhe a expressão onde adicionar mais um termo deixa de compensar a queda de erro. O SymTorch (TAN; SOUBKI; CRANMER, 2026), sucessor direto do método de Cranmer et al. (2020) pelo mesmo autor principal, automatiza a coleta de entradas e saídas de um bloco de uma rede PyTorch arbitrária e a substituição por uma expressão diferenciável, permitindo reajustar as constantes da expressão final de ponta a ponta – e também contribui uma regularização por *pruning* que descobre a dimensão intrínseca da mensagem sem precisar fixá-la a priori.

2.4 Explicação de GNNs por subgrafo

Uma segunda família de métodos, complementar à destilação simbólica, explica uma GNN treinada identificando qual subgrafo – quais arestas – foi mais relevante para uma predição, sem produzir uma equação. Ying et al. (2019) propuseram o GNNExplainer, que otimiza uma máscara sobre as arestas de uma instância específica maximizando a informação mútua entre o subgrafo mascarado e a predição original. Luo et al. (2020) propuseram o PGExplainer, que em vez de otimizar uma máscara por instância *treina uma rede* que prevê a máscara a partir dos embeddings dos nós, usando a relaxação *Concrete* (MADDISON; MNIH; TEH, 2017) para manter a máscara diferenciável durante o treino; isso o torna amortizado e indutivo, generalizando a instâncias não vistas sem reotimização. Yuan et al. (2021) propuseram o SubgraphX, que explora subgrafos conectados via busca em árvore Monte Carlo e os pontua pelo valor de Shapley (SHAPLEY, 1953) – mais fiel, porém mais caro computacionalmente. Faber, Moghaddam e Wattenhofer (2021) alertam que explainers de GNN nem sempre superam baselines triviais de grau ou peso de aresta quando avaliados com cuidado, o que reforça a necessidade de validar qualquer resultado de explicação contra ferramentas clássicas de identificação, como o RGA e a causalidade de Granger mencionados na Subseção 2.1.

3 Metodologia

A Figura 1 resume as etapas do método: (i) preparação dos dados e análise exploratória, (ii) treino da arquitetura em grafo com regularização de mensagem, (iii) avaliação de acurácia contra o ARMAX de referência e (iv) extração de equação e de topologia a partir do modelo treinado.

Figure 1 – Fluxograma das etapas do método

dados brutos → limpeza e EDA → treino da MPNN (com L1 na mensagem)
→ avaliação de acurácia (vs. ARMAX) → destilação simbólica (ψ , ϕ) e
topologia (*edge_strength*) → validação contra Granger/RGA

Fonte: Elaborado pelo autor.


3.1 Dados

Os dados usados são as 2.216 amostras horárias do reservatório São José (27/07/2014 a 27/10/2014), o dobro do recorte de 1.100 amostras usado por Ferrari e Coelho (2025). A análise exploratória identificou 25 amostras problemáticas (1,1% do total) – oito marcadas como falha pelo SCADA, oito com nível fisicamente inconsistente ($y_2 < 1$ m), variações de nível impossíveis em uma hora, vazão negativa e pressão abaixo de 5 mca – removidas antes do treino. Todas as sete séries (quatro entradas, três saídas) são estacionárias pelo teste de Dickey-Fuller aumentado ($p < 0,05$) e exibem um ciclo diário dominante (período ≈ 24 h) na densidade espectral. A Figura 2 mostra a correlação linear entre as sete variáveis: o nível do reservatório é a saída mais isolada linearmente das demais (correlação $< 0,10$ com as três frequências de bomba), o que é esperado, já que o nível responde à integral do desbalanço de vazão, não ao seu valor instantâneo.

A causalidade de Granger (Figura 3), calculada sobre as séries sem tendência com defasagem de até 12 h, confirma essa leitura: a vazão de entrada é a causa mais forte sobre o nível, com o lag mínimo possível (1 h, $p \approx 5 \times 10^{-124}$) – exatamente o comportamento esperado de um balanço de massa de primeira ordem. Essa matriz serve de referência externa e independente para validar a topologia de acoplamento que o modelo em grafo aprender (Subseção 3.3).


Como segunda referência clássica, um modelo ARX de ordem 2 ($y[k] = a_1y[k-1] + a_2y[k-2] + b_0u[k] + b_1u[k-1]$) foi ajustado por mínimos quadrados para cada um dos 12 pares entrada-saída. Todos os 12 modelos resultaram estáveis, com o par vazão de entrada → nível obtendo o menor erro (RMSE 0,104) entre todos – consistente com a resposta ao impulso concentrada em 1–2 h mostrada na Figura 4.

Figure 2 – Correlação de Pearson entre as sete variáveis do sistema



Fonte: Elaborado pelo autor.

Figure 3 – Causalidade de Granger entre as sete variáveis (log10 do p-valor no melhor lag)




Fonte: Elaborado pelo autor.

3.2 Arquitetura e treino

A arquitetura proposta (MPNNForecaster, implementada em `src/mimo_sys/architectures/` do repositório do projeto) é uma MPNN totalmente conectada sobre os sete nós do sistema, com a janela de defasagem de cada série como representação de nó. A função de mensagem ψ (Equação 1) recebe a concatenação das janelas do nó receptor e do nó emissor e produz um vetor de mensagem de dimensão reduzida; a função de atualização ϕ (Equação 2) combina a

Figure 4 – Predito vs. real – ARX de ordem 2, par vazão de entrada → nível



Fonte: Elaborado pelo autor.

janela do próprio nó com a soma das mensagens recebidas para produzir a previsão. Ambas são implementadas como percéptrons de multicamadas pequenos (duas camadas ocultas), e a penalidade L1 sobre a norma da mensagem é somada à função de perda de treino com peso 10^{-2} , seguindo Cranmer et al. (2020).

Duas variantes dessa arquitetura foram avaliadas: a `MPNNForecaster` padrão e a `SymbolicGraphNN` (CHEN et al., 2026), que adiciona um filtro Savitzky-Golay como *warm start* geométrico e injeção de ruído gaussiano dependente do ruído estimado durante o treino, visando robustez em registros curtos e ruidosos – o cenário deste trabalho, com apenas ~ 600 amostras de estimação após a limpeza. Como baselines de acurácia, sem papel na extração simbólica (por operarem sobre representações latentes sem nome, ver Subseção 3.3), foram também treinados o `StemGNN` (CAO et al., 2020) e o `Seq2SeqLatentGNN` (SEMAN et al., 2026), além de um `Seq2Seq` com atenção sem estrutura de grafo.

Todas as arquiteturas foram treinadas em um split cronológico 70/15/15 (treino/validação/teste) sobre o dataset completo de 2.216 amostras, com janela de entrada de 24 horas e previsão encadeada de 12 passos (12 horas) no teste, seguindo o mesmo protocolo usado para comparar com o ARMAX/MOGWO publicado.

3.3 Extração de equação e de topologia

A extração de equação (Rota A) segue o protocolo de dois estágios de Cranmer et al. (2020): primeiro destila-se ψ a partir dos pares (janela do receptor, janela do emissor) → mensagem, coletados de todas as 42 arestas dirigidas do grafo completo sobre um conjunto de validação; depois destila-se ϕ a partir dos pares (janela própria, mensagem agregada) → previsão, usando a mensagem já reduzida do primeiro estágio. A expressão final é a composição $\phi \circ \Sigma \circ \psi$, com as constantes reajustadas de ponta a ponta sobre a expressão composta. Essa etapa foi implementada como o módulo `mimo_sys.explainers.equation` do projeto, usando o PySR (CRANMER, 2023) como motor de busca; os resultados da destilação em si, sobre o modelo final treinado, estão em andamento no momento da escrita deste artigo (Seção 4.3).

A extração de topologia (Rota B) lê a norma média da mensagem por aresta, $S_{ij} = \frac{1}{B} \sum_b \|m_{ij}^{(b)}\|_2$, sobre um conjunto de amostras B – uma matriz 7×7 que não exige treino adicional, pois é o mesmo mecanismo de regularização L1 que torna a mensagem interpretável (Subseção

2.3). Essa matriz é comparada qualitativamente com a causalidade de Granger (Figura 3) como validação independente, seguindo a ressalva de Faber, Moghaddam e Wattenhofer (2021) de que atribuições de GNN devem ser confrontadas com baselines clássicos antes de serem aceitas. Um explainer amortizado (PGExplainer, Luo et al. (2020)) está implementado como alternativa de reserva, para o caso em que a matriz de mensagem discorde da validação clássica, mas não foi necessário neste trabalho.

4 Resultados e discussões

4.1 Acurácia: redes em grafo vs. ARMAX/MOGWO

A Tabela 1 compara o ARMAX/MOGWO publicado por Ferrari e Coelho (2025) com as cinco redes neurais treinadas, todas avaliadas em previsão encadeada de 12 passos no mesmo conjunto de teste.

Table 1 – R^2 em previsão de 12 passos, por saída

Modelo	R^2 vazão	R^2 nível	R^2 pressão
ARMAX (1 passo, referência)	0,915	0,932	0,671
ARMAX (12 passos)	0,570	0,293	0,148
Seq2Seq com atenção	0,877	0,435	0,653
MPNN	0,909	0,248	0,667
SymbolicGraphNetwork	0,915	0,260	0,693
StemGNN	0,889	0,386	0,594
Seq2SeqLatentGNN	0,875	0,304	0,633

Fonte: Elaborado pelo autor.

Todas as cinco redes superam o ARMAX de 12 passos nas três saídas. Nenhuma rede se aproxima do ARMAX de 1 passo – comparação que não é justa, já que o ARMAX de 1 passo recebe a saída medida a cada passo, enquanto as redes fazem previsão livre de 12 passos à frente; esse número serve apenas como teto de referência. Entre as redes, a *SymbolicGraphNetwork* obtém a melhor vazão e pressão, e é a única, junto da *MPNNForecaster*, que mantém a função de mensagem nomeável e portanto candidata à destilação simbólica da Subseção 4.3 – o *StemGNN*, apesar de ser a única rede a melhorar o nível (R^2 0,386), opera sobre uma base espectral aprendida e não admite esse tipo de extração (Subseção 2.4). O nível é a saída mais difícil para todas as redes em grafo, resultado consistente com ele ser a variável de estado genuína do sistema (um integrador), mais sensível ao viés acumulado em previsão livre de 12 passos do que as saídas quase-algébricas (vazão e pressão).

4.2 Topologia do acoplamento

A leitura preliminar da matriz de norma de mensagem (S_{ij} , Subseção 3.4) do modelo *SymbolicGraphNetwork* treinado concorda qualitativamente com a causalidade de Granger

da Figura 3: a linha correspondente ao nível concentra a maior parte de seu peso de entrada na vazão de entrada, e as linhas de vazão de distribuição e pressão concentram peso nas três frequências de bomba – consistente com a ausência de relação direta entre as frequências de bomba e o nível observada na correlação linear (Figura 2) e com o mecanismo físico de perda de carga dependente de vazão, não de nível. Essa concordância entre dois métodos independentes – rede treinada e causalidade estatística clássica – é evidência a favor de que a topologia aprendida reflete acoplamento físico real, e não um artefato do treino.

4.3 Estado da destilação simbólica

A destilação da função de mensagem ψ e da função de atualização ϕ (Subseção 3.4) está implementada como código (`mimo_sys.explainers.equation`), mas a execução sobre o modelo final treinado com os hiperparâmetros de produção, e a validação quantitativa da expressão resultante contra o balanço de massa conhecido ($A dy_2/dt = u_4 - y_1$), ainda não haviam sido concluídas no momento da escrita deste artigo. Os resultados de acurácia da Subseção 4.1 foram obtidos com `message_dim=8`, dimensão escolhida para favorecer acurácia; a extração simbólica, seguindo Cranmer et al. (2020), exige uma mensagem de dimensão muito menor (2–3) para a busca simbólica permanecer tratável, o que implica treinar uma variante adicional antes de destilar. Essa etapa, junto da validação fora da distribuição e da comparação com um baseline SINDy direto sobre os sinais, é o próximo passo deste trabalho e deverá compor a versão final deste artigo.

5 Conclusões

Este trabalho propôs um método para extrair, de uma rede neural em grafo treinada para identificar um sistema MIMO de abastecimento de água, tanto uma matriz de topologia de acoplamento quanto – potencialmente – uma equação simbólica interpretável, endereçando a lacuna deixada pelo modelo ARMAX caixa-preta de Ferrari e Coelho (2025). Os resultados obtidos até aqui confirmam a primeira parte da hipótese de trabalho: arquiteturas em grafo pensadas para extração (MPNN, SymbolicGraphNetwork) alcançam acurácia de previsão de 12 passos igual ou superior à de arquiteturas mais complexas (StemGNN, Seq2SeqLatentGNN) e muito superior ao ARMAX de mesmo horizonte, usando uma fração dos parâmetros do modelo publicado. A segunda parte da hipótese – que a expressão simbólica destilada recupera, qualitativamente, o balanço de massa conhecido do reservatório – depende da conclusão da etapa de destilação simbólica, que é o objetivo imediato da continuação deste trabalho.

Agradecimentos

O autor agradece ao Centro Universitário Curitiba (Unicuritiba) e ao professor orientador pelo acompanhamento deste trabalho.

Bibliography

BATTAGLIA, P. W.; HAMRICK, J. B.; BAPST, V.; SANCHEZ-GONZALEZ, A.; ZAMBALDI, V.; MALINOWSKI, M.; TACCHETTI, A.; RAPOSO, D.; SANTORO, A.; FAULKNER, R.; GULCEHRE, C.; SONG, F.; BALLARD, A.; GILMER, J.; DAHL, G.; VASWANI, A.; ALLEN, K.; NASH, C.; LANGSTON, V.; DYER, C.; HEESS, N.; WIERSTRA, D.; KOHLI, P.; BOTVINICK, M.; VINYALS, O.; LI, Y.; PASCANU, R. **Relational Inductive Biases, Deep Learning, and Graph Networks**. 2018. ArXiv preprint arXiv:1806.01261.

BRISTOL, E. On a new measure of interaction for multivariable process control. **IEEE Transactions on Automatic Control**, v. 11, n. 1, p. 133–134, 1966.

CAO, D.; WANG, Y.; DUAN, J.; ZHANG, C.; ZHU, X.; HUANG, C.; TONG, Y.; XU, B.; BAI, J.; TONG, J.; ZHANG, Q. **Spectral Temporal Graph Neural Network for Multivariate Time-Series Forecasting**. 2020. ArXiv:2103.07719.

CHEN, X.; AN, J.; GUO, J.; ZHOU, Y. **Symbolic Graph Networks for Robust PDE Discovery from Noisy Sparse Data**. 2026. ArXiv preprint arXiv:2603.22380.

CRANMER, M. **Interpretable Machine Learning for Science with PySR and SymbolicRegression.jl**. 2023. ArXiv preprint arXiv:2305.01582.

CRANMER, M.; SANCHEZ-GONZALEZ, A.; BATTAGLIA, P.; XU, R.; CRANMER, K.; SPERGEL, D.; HO, S. Discovering symbolic models from deep learning with inductive biases. In: **Advances in Neural Information Processing Systems (NeurIPS)**. [S.l.: s.n.], 2020. v. 33. ArXiv:2006.11287.

FABER, L.; MOGHADDAM, A. K.; WATTENHOFER, R. When comparing to ground truth is wrong: On evaluating gnn explanation methods. 2021.

FERRARI, L.; COELHO, L. d. S. Multi-objective metaheuristics applied for the multivariable system identification. **International Journal of Parallel, Emergent and Distributed Systems**, 2025. DOI: 10.1080/17445760.2025.2508174.

GILMER, J.; SCHOENHOLZ, S. S.; RILEY, P. F.; VINYALS, O.; DAHL, G. E. Neural message passing for quantum chemistry. In: **Proceedings of the 34th International Conference on Machine Learning (ICML)**. [S.l.: s.n.], 2017. ArXiv:1704.01212.

GRANGER, C. W. J. Investigating causal relations by econometric models and cross-spectral methods. **Econometrica**, v. 37, n. 3, p. 424–438, 1969.

KOZA, J. R. **Genetic Programming: On the Programming of Computers by Means of Natural Selection**. Cambridge, MA: MIT Press, 1992.

LJUNG, L. **System Identification: Theory for the User**. 2. ed. Upper Saddle River: Prentice Hall, 1999.

LUO, D.; CHENG, W.; XU, D.; YU, W.; ZONG, B.; CHEN, H.; ZHANG, X. Parameterized explainer for graph neural network. In: **Advances in Neural Information Processing Systems (NeurIPS)**. [S.l.: s.n.], 2020. v. 33. ArXiv:2011.04573.

MADDISON, C. J.; MNIH, A.; TEH, Y. W. The concrete distribution: A continuous relaxation of discrete random variables. In: **International Conference on Learning Representations (ICLR)**. [S.l.: s.n.], 2017.

SCHMIDT, M.; LIPSON, H. Distilling free-form natural laws from experimental data. **Science**, v. 324, n. 5923, p. 81–85, 2009.

SEMAN, L. O.; STEFENON, S. F.; YOW, K.-C.; COELHO, L. d. S.; MARIANI, V. C. Fourier-enhanced sequence-to-sequence latent graph neural networks for multi-node spatiotemporal forecasting in a hydroelectric reservoir. **Engineering Applications of Artificial Intelligence**, v. 167, n. 3, 2026.

SHAPLEY, L. S. A value for n-person games. In: KUHN, H. W.; TUCKER, A. W. (Ed.). **Contributions to the Theory of Games II**. Princeton: Princeton University Press, 1953. p. 307–317.

SKOGESTAD, S.; POSTLETHWAITE, I. **Multivariable Feedback Control: Analysis and Design**. 2. ed. Chichester: Wiley, 2005.

TAN, E. S. Z.; SOUBKI, A.; CRANMER, M. **SymTorch: Symbolic Distillation of Neural Networks**. 2026. ArXiv preprint arXiv:2602.21307.

TIBSHIRANI, R. Regression shrinkage and selection via the lasso. **Journal of the Royal Statistical Society: Series B**, v. 58, n. 1, p. 267–288, 1996.

YING, R.; BOURGEOIS, D.; YOU, J.; ZITNIK, M.; LESKOVEC, J. Gnnexplainer: Generating explanations for graph neural networks. In: **Advances in Neural Information Processing Systems (NeurIPS)**. [S.l.: s.n.], 2019. v. 32. ArXiv:1903.03894.

YUAN, H.; YU, H.; WANG, J.; LI, K.; JI, S. On explainability of graph neural networks via subgraph explorations. In: **Proceedings of the 38th International Conference on Machine Learning (ICML)**. [S.l.: s.n.], 2021. ArXiv:2102.05152.